LETTRES SORBONNE UNIVERSITÉ

# Indexation sémantique et recherche d'information

Ruixing ZHENG

Master 2 Langue & Informatique

# Table de matières

1. Introduction du corpus
2. Création du schéma
3. Indexation du corpus
4. Création des facettes et Modification de Velocity
5. Difficultés rencontrées
6. Conclusion

# 1. Introduction du corpus

- Objectif du Projet :

Construire un moteur de recherche basé sur Solr pour explorer des activités culturelles françaises.

- Corpus Choisi :

La collection #CultureChezNous (data.gouv.fr) proposée par le gouvernement français.

Taille et Format :
1149 ressources au format CSV

Attributs Clés :
Organisation, titre, activité, public cible, type de ressource, thématiques, adresse, coordonnées géographiques, et URL.

# 1. Introduction du corpus

- Problèmes du Corpus Initial :
  Manque de champs booléens, de date

- Solution : Développement d'un script Python pour enrichir et nettoyer les données
  Champs ajoutés/modifiés :

❖ Date convient au Solr
❖ is_for_kids : si public == "Enfants"
❖ is_accessible : basé sur la présence d'adaptations pour personnes handicapées
❖ long_duration : si duree_min est plus de 120 minutes

- Corpus Final : 28 colonnes, 1149 documents validés et nettoyés.

# 2. Création du schéma

- Champs Textuels (Type text_fr) :
  titre, description, activite

- Champs de Facettes (Type string) :
  commune, public, type_ressource, thematiques (multi-valués)

- Champs Numériques :
  duree_min (pint) pour la durée en minutes

managed-schema

solr-8.11.2/server/solr/culture/conf/managed-schema (functions)

```
<!-- Basic string fields (not analyzed, correct for facets) -->
<field name="org_nom" type="string" indexed="true" stored="true"/>
<field name="org_adresse" type="string" indexed="true" stored="true"/>
<field name="code_postal" type="string" indexed="true" stored="true"/>
<field name="commune" type="string" indexed="true" stored="true" multiValued="false"/>
<field name="url" type="string" indexed="false" stored="true"/>
<field name="niveau_enfant" type="string" indexed="true" stored="true"/>
<field name="public" type="string" indexed="true" stored="true" multiValued="false"/>
<field name="duree_txt" type="string" indexed="true" stored="true"/>
<field name="perennite" type="string" indexed="true" stored="true"/>
<field name="rattachement" type="string" indexed="true" stored="true"/>
<field name="thematique_autre" type="string" indexed="true" stored="true"/>
<field name="autre_precise" type="string" indexed="true" stored="true"/>

<!-- Text fields (need full text search) -->
<field name="titre" type="text_fr" indexed="true" stored="true"/>
<!-- Facet-friendly version of titre (no stemming, no analysis) -->
<field name="titre_facet" type="string" indexed="true" stored="false" docValues="true"/>
<!-- 这里是标题的 facet-friendly 副本 -->
<copyField source="titre" dest="titre_facet"/>

<field name="activite" type="text_fr" indexed="true" stored="true"/>
<field name="description" type="text_fr" indexed="true" stored="true"/>

<!-- Multi-valued facet fields MUST BE string -->
<field name="type_ressource" type="string" indexed="true" stored="true" multiValued="true"/
<field name="thematiques" type="string" indexed="true" stored="true" multiValued="true"/>
<field name="handicap_adapt" type="string" indexed="true" stored="true" multiValued="true"/

<!-- Numeric fields -->
<field name="lat" type="pdouble" indexed="true" stored="true"/>
<field name="lon" type="pdouble" indexed="true" stored="true"/>
<field name="code_postal_num" type="pint" indexed="true" stored="true"/>
<field name="duree_min" type="pint" indexed="true" stored="true"/>
<field name="date" type="pdate" indexed="true" stored="true" multiValued="false"/>


<!-- Boolean facet fields -->
<field name="long_duration" type="boolean" indexed="true" stored="true"/>
<field name="is_for_kids" type="boolean" indexed="true" stored="true"/>
<field name="is_accessible" type="boolean" indexed="true" stored="true"/>
```

# 3. Indexation du corpus

Résultats de l'Indexation :

- Nombre de Documents : 1149

- Test de Base :

La requête q=*.* retourne l'ensemble des 1149 documents avec les champs correctement remplis et les facettes affichées.

**Statistics**

| | |
|---|---|
| Last Modified: | 14 days ago |
| Num Docs: | 1149 |
| Max Doc: | 1149 |
| Deleted Docs: | 0 |
| Version: | 54 |
| Segment Count: | 1 |
| Current: | ✔ |

Request-Handler (qt)
/select

common

q
*:*

q.op
OR

fq

sort

start, rows
0 10

fl

df

paramset(s)
Select paramset(s)...

wt
------

indent on

debugQuery

defType
------

hl

facet

spatial

spellcheck

Raw Query Parameters

JSON Query

http://localhost:8983/solr/culture/select?indent=true&q.op=OR&q=*%3A*


```
{
  "responseHeader":{
    "status":0,
    "QTime":0,
    "params":{
      "q":"*:*",
      "indent":"true",
      "q.op":"OR",
      "_":"1764580160881"}},
  "response":{"numFound":1149,"start":0,"numFoundExact":true,"docs":[
      {
        "id":"588",
        "org_nom":"Archives départementales - Calvados",
        "org_adresse":"61 rue de Lion-sur-Mer",
        "code_postal":"14000",
        "commune":"Caen",
        "url":"https://archives.calvados.fr/editorial/page/39663280-35ce-46ff-95c4-4fad9b7dbfc6#",
        "titre":"Archives en ligne",
        "activite":"Approfondir ses connaissances",
        "public":"Tous publics",
        "type_ressource":["IMAGES",
          "COLLECTIONS NUMÉRISÉES",
          "BASES DE DONNÉES"],
        "thematiques":["ARCHIVES"],
        "duree_txt":"Le temps d'une soirée",
        "perennite":"Accès permanent",
        "rattachement":"Collectivité territoriale",
        "geo":"49.201873,-0.354741",
        "lat":49.201873,
        "lon":-0.354741,
        "code_postal_num":14000,
        "duree_min":120,
        "description":"Des contenus ludiques pour les plus jeunes aux documents pour faire sa généalogie, des images
        "long_duration":false,
        "is_for_kids":false,
        "is_accessible":false,
        "date":"2023-01-10T00:00:00Z",
        "_version_":1849002470634684416,
        "titre_facet":"Archives en ligne"},
      {
        "id":"678",
```

# 4. Création des facettes et Modification de Velocity

- Field Facets :
  Activées pour thematiques, type_ressource, commune, et public.

- Query Facets (Booléennes) :
  is_for_kids:true (110 ressources)
  is_accessible:true (180 ressources)
  long_duration:true (198 ressources)

- Range Facets (Intervalles) :
  - ❖ Durée (duree_min) :
    0 à 150 minutes, écart de 30 minutes
    (ex. 0-30 min: 345 ressources)
  - ❖ Année (date) :
    Du 01/01/2022 au 27/08/2025, écart d'un an
    (ex. 2023: 332 ressources)

- Pivot Facets :
  Croisement commune / type_ressource
  (ex. Paris: 15 VIDÉO, 13 EXPOSITIONS VIRTUELLES)

solrconfig.xml

o/solr-8.11.2/server/solr/culture/conf/solrconfig.xml

```xml
<!-- Field facets -->
<str name="facet.field">thematiques</str>
<str name="facet.field">type_ressource</str>
<str name="facet.field">commune</str>
<str name="facet.field">public</str>
<str name="facet.query">is_for_kids:true</str>
<str name="facet.query">is_accessible:true</str>
<str name="facet.query">long_duration:true</str>

<!-- QUERY FACETS - 完整统计 -->
<str name="facet.query">is_for_kids:true</str>
<str name="facet.query">is_for_kids:false</str>


<str name="facet.query">is_accessible:true</str>
<str name="facet.query">is_accessible:false</str>


<str name="facet.query">long_duration:true</str>
<str name="facet.query">long_duration:false</str>



<!-- Range facets -->
<str name="facet.range">duree_min</str>
<str name="f.duree_min.facet.range.start">0</str>
<str name="f.duree_min.facet.range.end">150</str>
<str name="f.duree_min.facet.range.gap">30</str>

<str name="facet.range">date</str>
<str name="f.date.facet.range.start">2022-01-01T00:00:00Z</str>
<str name="f.date.facet.range.end">2025-08-27T00:00:00Z</str>
<str name="f.date.facet.range.gap">+1YEAR</str>

<!-- Pivot facets -->
<str name="facet.pivot">commune,type_ressource</str>
<str name="facet.pivot.mincount">1</str>
```

# 4. Création des facettes et Modification de Velocity

Objectif :
Améliorer la lisibilité pour l'utilisateur.

Changement des labels :
"Durée" au lieu de "duree_min" et "Année" au lieu de "date"

VM_global_library.vm

esktop/solr-8.11.2/server/solr/culture/conf/velocity/VM_global_library.vm (no function s

```
#macro(display_facet_range $field, $display, $fieldName, $start, $end, $gap, $before,
<span class="facet-field">
  ## 自定义字段显示名称
  #if($fieldName == "duree_min")
    Durée
  #elseif($fieldName == "date")
    Année
  #else
    $display
  #end
</span>
<ul>
  #if($before && $before != "")
    #set($value = "[* TO " + "#format_value($start)" + "}")
    #set($facetURL = "#url_for_facet_range_filter($fieldName, $value)")
    <li><a href="$facetURL">Less than #format_value($start)</a> ($before)</li>
  #end

  #foreach ($facet in $field)
    #set($rangeEnd = "#range_get_to_value($facet.key, $gap)")
    #set($value    = "[" + $facet.key + " TO " + $rangeEnd + "}")
    #set($facetURL = "#url_for_facet_range_filter($fieldName, $value)")
    #if ($facetURL != '')
      <li>
        <a href="$facetURL">
          ## 针对 date 字段，只显示年份
          #if($fieldName == "date")
            $facet.key.substring(0, 4)
          ## 针对 duree_min 字段，保持原样
          #elseif($fieldName == "duree_min")
            $facet.key - #format_value($rangeEnd)
          ## 其他字段保持原样
          #else
            $facet.key - #format_value($rangeEnd)
          #end
        </a>
        <span class="count">($facet.value)</span>
      </li>
    #end
  #end
```

# 5. Difficultés rencontrées

- Difficulté Majeure : Le Mapping.

- Problème :

Le passage au fournisseur CartoDB n'a pas fonctionné

- Perspectives d'Amélioration :

❖ Améliorer la fonctionnalité de la carte interactive

❖ Ajouter un bouton "Afficher la carte" pour charger la carte à la demande.

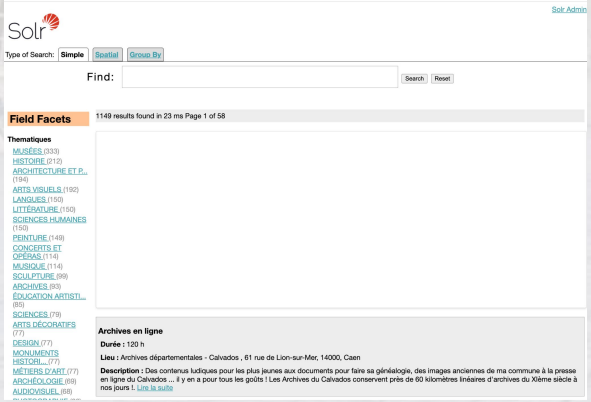


browse.vm

esktop/solr-8.11.2/server/solr/culture/conf/velocity/browse.vm [ anonymous ]

```
## Show Error Message, if any
#if($response.error)
<div class="error">
  #parse("error.vm")
</div>
#end


## Map
<div id="map" style="height: 400px; margin-left: 210px; margin-top: 20px; border: 1px solid #ccc;"></div>
<script>
document.addEventListener("DOMContentLoaded", function () {
    var map = L.map('map').setView([46.5, 2.5], 6);

    // 使用 CartoDB 地图源（更稳定）
    L.tileLayer('https://{s}.basemaps.cartocdn.com/light_all/{z}/{x}/{y}{r}.png', {
        attribution: '© OpenStreetMap © CartoDB',
        maxZoom: 19
    }).addTo(map);

    // 添加标记
    #foreach($doc in $response.results)
        #set($lat = $doc.getFieldValue("lat"))
        #set($lon = $doc.getFieldValue("lon"))
        #set($titre = $esc.javascript($doc.getFieldValue("titre")))
        #if($lat && $lon)
            L.marker([$lat, $lon])
             .addTo(map)
             .bindPopup("<b>$titre</b>");
        #end
    #end
});
</script>
```

# 6. Conclusion

- Réussite du Projet :

Construction d'un moteur de recherche pertinent pour l'exploration d'activités culturelles françaises

- Compétences Acquises :

L'expérience avec Solr est une base solide pour de futurs projets de recherche d'information

- Démonstration :

La recherche par mot-clé ("paris" - 59 résultats) et le filtrage par facette ("MUSÉES" - 514 résultats) montrent la navigation fluide et le recalcul automatique des facettes

- Code Source :

L'ensemble du code est fourni dans le dossier de soumission pour vérification

http://localhost:8983/solr/culture/browse?q=

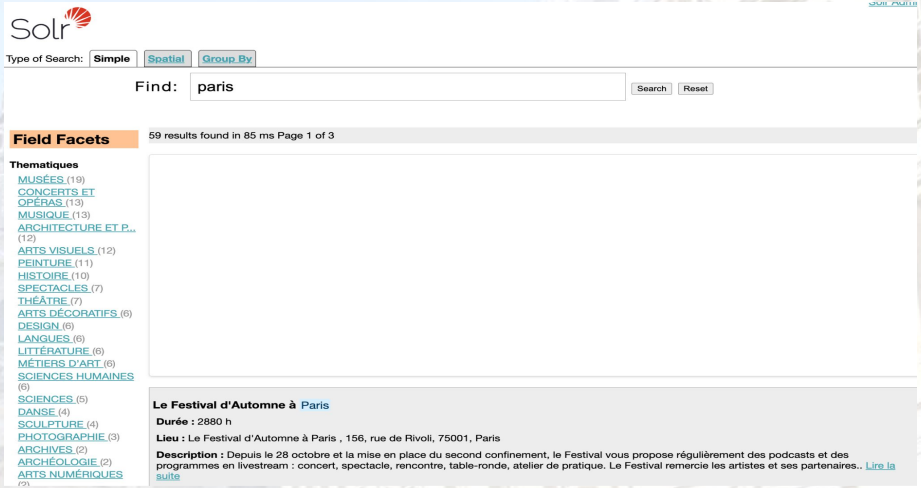


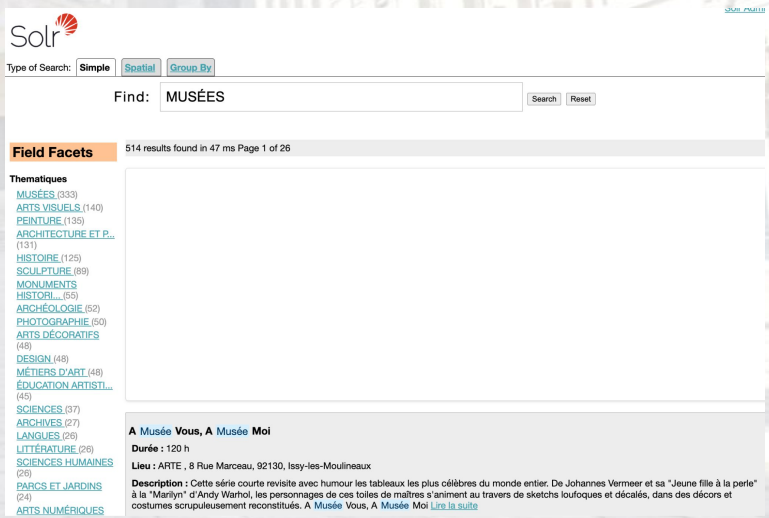

Merci pour votre attention!