Indexation sémantique et recherche d'information

Master 2 Langue & Informatique

Projet Final

ZHENG RUIXING

Année Universitaire 2025-2026

Introduction et motivation du projet

L'objectif de ce projet est de construire un moteur de recherche basé sur Apache Solr pour explorer les ressources culturelles numériques françaises. En tant qu'amateur d'activités culturelles, j'ai choisi le corpus **#CultureChezNous** proposé par le gouvernement français, qui regroupe plus de 1000 ressources culturelles accessibles en ligne (musées virtuels, concerts, expositions, podcasts, etc.).

Ce choix nous permet de créer un outil pratique pour explorer l'offre culturelle numérique française selon différents critères : thématique, type de ressource, durée, accessibilité, localisation géographique, etc.

Sélection du corpus

Le corpus choisi provient de la plateforme data.gouv.fr, spécifiquement la collection **#CultureChezNous** (https://www.data.gouv.fr/datasets/culturecheznous/). Il contient 1149 ressources culturelles au format CSV avec un séparateur point-virgule. Les attributs principaux incluent l'organisation, le titre, l'activité, le public cible, le type de ressource, les thématiques, l'adresse, les coordonnées géographiques et l'URL.

```
ant;titre;activite;public;type_ressource;thematiques;handicap_adapt;duree_txt;perennite;rattachement;thematique_autre;autre_precise;geo;lat;lon;code_postal_num;duree_min;description;long_duratic
r-Mer;14000;Caen;https://archives.calvados.fr/editorial/page/39663280-35ce-46ff-95c4-4fad9b7dbfc6#;;Archives en ligne;Approfondir ses connaissances;Tous publics;IMAGES|COLLECTIONS NUMÉRISÉES|BAS
Mauriac;75706;Paris;https://gallica.bnf.fr/essentiels/;;Gallica - Essentiels de la littérature;Livres;Tous publics;LIVRES NUMÉRIQUES;HISTOIRE|LITTÉRATURE|SCIENCES HUMAINES|LANGUES;;Toute une vie
ps://savoirs.ens.fr/recherche.php?class=8&rechercheOption=ThemeRacine&rechercheTerme=Arts&classe=Lettres;;Conférences sur l'art et les jeux vidéos;Approfondir ses connaissances;Tous publics;AUDI
es Frères-Lumière;94366;Bry-sur-Marne;https://www.youtube.com/user/Inahistoire;;INA Histoire;Films, documentaires, vidéos;Tous publics;VIDÉO|FLUX EN DIRECT|PROGRAMMES EN DIFFÉRÉ|EXPOSITIONS VIR
d Paris;Médiathèque Pablo Neruda, 24 Rue Béranger.;92240;Malakoff;https://www.youtube.com/user/MediathequeMalakoff/playlists;Maternelle;La Médiathèque de Malakoff sur YouTube;Partager ses passic
s://www.lillemetropole.fr/actualites/bibliomobi-le-plein-de-lectures-ou-et-quand-vous-voulez-et-gratuitement;;Bibliomobi;Livres;Tous publics;LIVRES NUMÉRIQUES;BANDE DESSINÉE|LITTÉRATURE|SCIENCES
cus.louvre.fr/;;Focus sur une oeuvre;Expos, musées;Tous publics;IMAGES|COLLECTIONS NUMÉRISÉES|BASES DE DONNÉES;PEINTURE|MUSÉES;;Le temps de manger un sandwich pendant une pause déjeuner;Accès pe
http://museefabre.extraart.fr;;"Visite virtuelle 360° de l'exposition ""Jean Ranc, un Montpelliérain à la cour des rois""";Expos, musées;Tous publics;EXPOSITIONS VIRTUELLES;ARTS DÉCORATIFS|DESIG
n;https://www.youtube.com/playlist?list=PLWoadw5rtauSnF5YouJ17mY-Hv21IHQSQ;;Les métier de l'Opéra;Films, documentaires, vidéos;Tous publics;VIDÉO|FLUX EN DIRECT|PROGRAMMES EN DIFFÉRÉ;DANSE|MUSIC
départemental de la Seine-Saint-Denis, Hôtel du Département, Esplanade Jean-Moulin;93000;Bobigny;https://archives.seinesaintdenis.fr/Archives-en-ligne/p219/Archives-en-ligne;;Archives en ligne;A
e Place de l'Etape;45040;Orléans;http://archives.orleans-metropole.fr/r/19/expositions-virtuelles/;;Orléans - Expositions virtuelles des Archives;Expos, musées;Tous publics;IMAGES|COLLECTIONS NU
odcast.ausha.co/histoires-jeunesse;;Podcast Histoires de jeunesse;Audios;Tous publics;AUDIO|RADIO|PODCASTS;LITTÉRATURE|SCIENCES HUMAINES|LANGUES;;Le temps de manger un sandwich pendant une pause
p://www.bibebook.com/visual-search;;1 700 livres numériques gratuits;Livres;Tous publics;LIVRES NUMÉRIQUES;LITTÉRATURE|SCIENCES HUMAINES|LANGUES;;Toute une vie ne suffit pas;Accès permanent;Orga
sité Paris 1 PAnthéon Sorbonne;75005;Paris;https://nubis.univ-paris1.fr/exhibits;;NuBIS, bibliothèque numérique;Expos, musées;Tous publics;IMAGES|COLLECTIONS NUMÉRISÉES|BASES DE DONNÉES;ARCHIVES
Mauriac;75706;Paris;http://classes.bnf.fr/echo/;;Entendre le théâtre;Audios;Tous publics;AUDIO|RADIO|PODCASTS;THÉÂTRE|SPECTACLES;;Le temps d'un vrai déjeuner;Accès permanent;Ministère de la Cult
on Carrée;30000;Nîmes;https://www.carreartmusee.com/fr/service-des-publics/ateliers-creatifs-a-faire-chez-soi/;;Ateliers créatifs à faire chez soi;Partager ses passions;Enfants;JEUX|CRÉATION ET
Louis Ricard;76000;Rouen;https://www.cdn-normandierouen.fr/ca-n-engage-a-rien-radio-hdr/;;« Ça n'engage à rien », le podcast du CDN de Normandie-Rouen;Audios;Tous publics;AUDIO|RADIO|PODCASTS;TH
antin;http://mediatheque.cnd.fr/spip.php?page=mediatheque-numerique-parcourir;;Médiathèque numérique;Approfondir ses connaissances;Tous publics;VIDÉO|FLUX EN DIRECT|PROGRAMMES EN DIFFÉRÉ;DANSE;;
phie;Quartier Villars, Route de Montilly;03000;Moulins;https://www.cncs.fr/activit%C3%A9s-num%C3%A9riques;;Multimédia;Expos, musées;Tous publics;EXPOSITIONS VIRTUELLES;MODE;;Le temps d'une soire
eurs-au-Bois;http://www.chateauchamerolles.fr/articles/visite-virtuelle;;Visite à 360° depuis votre canapé !;Expos, musées;Tous publics;EXPOSITIONS VIRTUELLES;ARCHITECTURE ET PATRIMOINE|HISTOIRE
ourogne;https://www.espacemultimediagantner.cg90.net/la-collection/;;Collection d'arts numériques;Expos, musées;Tous publics;IMAGES|COLLECTIONS NUMÉRISÉES|BASES DE DONNÉES|EXPOSITIONS VIRTUELLES
vienne;75002;Paris;https://bibliotheque-numerique.inha.fr/;;Bibliothèque numérique;Expos, musées;Tous publics;IMAGES|COLLECTIONS NUMÉRISÉES|BASES DE DONNÉES;HISTOIRE|MUSÉES|PEINTURE|SCULPTURE;;
anterre;200 avenue de la République;92000;Nanterre;http://naissanceethnologie.fr/;;A la naissance de l'ethnologie française;Expos, musées;Tous publics;IMAGES|COLLECTIONS NUMÉRISÉES|BASES DE DONN
://museelansyer-loches.fr/;;Visite virtuelle;Expos, musées;Tous publics;EXPOSITIONS VIRTUELLES;ARCHITECTURE ET PATRIMOINE|MUSÉES|PARCS ET JARDINS;NAVIGATION AU CLAVIER;Le temps d'un vrai déjeune
64100;Bayonne;http://www.musee-basque.com/visites-activites/parcours-a-themes/;;Parcours à thèmes;Expos, musées;Tous publics;EXPOSITIONS VIRTUELLES;ARCHITECTURE ET PATRIMOINE|MUSÉES;;Le temps d'
es Lycéens Martyrs;22000;Saint-Brieuc;https://caramboleetconfinement.fr/;;Caramboles et confinement;Jeux;Tous publics;IMAGES|COLLECTIONS NUMÉRISÉES|BASES DE DONNÉES|JEUX;PHOTOGRAPHIE;TRANSCRIPTI
nt-Germain-en-Laye, Château-Place Charles de Gaulle;78100;Saint-Germain-en-Laye;https://archeologie.culture.fr/fr;;Grands Sites Archéologiques;Expos, musées;Tous publics;EXPOSITIONS VIRTUELLES;A
https://www.youtube.com/watch?v=VLP4qMLsqxs&list=PLyPnohnEv52fVHBNBZ0nsh4rsxCASbwqX;;Musée Accessible;Expos, musées;Tous publics;VIDÉO|FLUX EN DIRECT|PROGRAMMES EN DIFFÉRÉ;MUSÉES;LANGUE DES SIGN
https://www.theatredelaville-paris.com/fr/spectacles/theatre-partage/les-consultations-poetiques-et-scientifiques/les-consultations-poetiques-et-musicales-par-telephone;;Consultations poétiques
s;https://vimeo.com/showcase/6974393;;Lettres de cinéma;Films, documentaires, vidéos;Tous publics;VIDÉO|FLUX EN DIRECT|PROGRAMMES EN DIFFÉRÉ;AUDIOVISUEL|CINÉMA;;Le temps d'un week-end;Accès perm
```

Annotation et prétraitement du corpus

Le corpus initial présentait plusieurs limitations pour l'indexation Solr. D'abord, il manquait des champs booléens. Ensuite, le format des dates était YYYY-MM-DD au lieu du format Solr requis YYYY-MM-DDTHH:MM:SSZ. Enfin, il n'y avait pas de champs calculés comme des indicateurs de "longue durée" ou "adapté aux enfants".

J'ai développé donc un script Python pour enrichir et nettoyer le corpus. Les colonnes ajoutées incluent : un champ *date* converti au format compatible Solr, un champ booléen *long_duration* calculé selon la règle duree_min >= 120 (c'est une règle définie par moi-même), un champ booléen is_for_kids basé sur le critère public == "Enfants", et un champ booléen *is_accessible* indiquant la présence d'adaptations pour personnes handicapées. Après traitement, le corpus final contient 28 colonnes, 1149 documents validés et nettoyés, et des types de données variés : string, text_fr, pint, pfloat, pdouble, pdate, boolean, location_rpt.

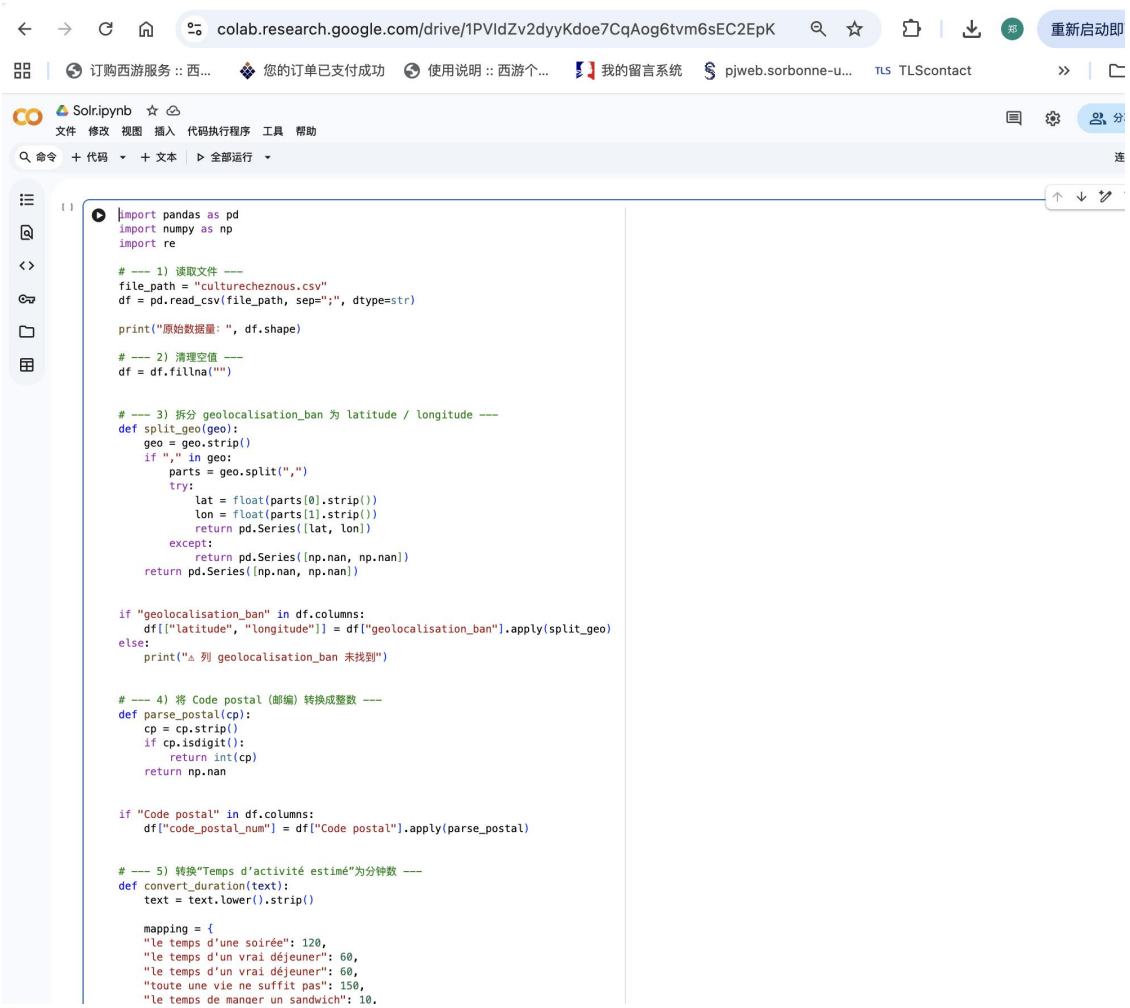

Création du schéma

J'ai défini aussi chaque champ du corpus dans le fichier managed-schema selon son type et son usage prévu.

- Les champs textuels incluent titre, description et activite (tous de type text_fr), sont indexés avec morphologique française.

- Les champs de facettes sans analyse sont de type string : commune pour la ville, public pour le public cible, type_ressource et thematiques (multi-valued) pour les thèmes culturels.

- Les champs numériques comprennent duree_min (pint) pour la durée en minutes.

- Les champs booléens long_duration, is_for_kids et is_accessible servent pour les Query Facets.

- Le champ temporel date (pdate) stocke la date de publication. Enfin, le champ géospatial geo (location_rpt) au format "lat,lon" permet les recherches géographiques.

managed-schema

~/Desktop/solr-8.11.2/server/solr/culture/conf/managed-schema

```
112
113     <field name="id" type="string" indexed="true" stored="true" required="true" multiValued="false" />
114     <!-- docValues are enabled by default for long type so we don't need to index the version field  -->
115     <field name="_version_" type="plong" indexed="false" stored="false"/>
116
117     <!-- If you don't use child/nested documents, then you should remove the next two fields:  -->
118     <!-- for nested documents (minimal; points to root document) -->
119     <field name="_root_" type="string" indexed="true" stored="false" docValues="false" />
120     <!-- for nested documents (relationship tracking) -->
121     <field name="_nest_path_" type="_nest_path_" /><fieldType name="_nest_path_" class="solr.NestPathField" />
122
123
124
125     <!-- Basic string fields (not analyzed, correct for facets) -->
126     <field name="org_nom" type="string" indexed="true" stored="true"/>
127     <field name="org_adresse" type="string" indexed="true" stored="true"/>
128     <field name="code_postal" type="string" indexed="true" stored="true"/>
129     <field name="commune" type="string" indexed="true" stored="true" multiValued="false"/>
130     <field name="url" type="string" indexed="false" stored="true"/>
131     <field name="niveau_enfant" type="string" indexed="true" stored="true"/>
132     <field name="public" type="string" indexed="true" stored="true" multiValued="false"/>
133     <field name="duree_txt" type="string" indexed="true" stored="true"/>
134     <field name="perennite" type="string" indexed="true" stored="true"/>
135     <field name="rattachement" type="string" indexed="true" stored="true"/>
136     <field name="thematique_autre" type="string" indexed="true" stored="true"/>
137     <field name="autre_precise" type="string" indexed="true" stored="true"/>
138
139     <!-- Text fields (need full text search) -->
140     <field name="titre" type="text_fr" indexed="true" stored="true"/>
141     <!-- Facet-friendly version of titre (no stemming, no analysis) -->
142     <field name="titre_facet" type="string" indexed="true" stored="false" docValues="true"/>
143     <!-- 这里是标题的 facet-friendly 副本 -->
144     <copyField source="titre" dest="titre_facet"/>
145
146     <field name="activite" type="text_fr" indexed="true" stored="true"/>
147     <field name="description" type="text_fr" indexed="true" stored="true"/>
148
149     <!-- Multi-valued facet fields MUST BE string -->
150     <field name="type_ressource" type="string" indexed="true" stored="true" multiValued="true"/>
151     <field name="thematiques" type="string" indexed="true" stored="true" multiValued="true"/>
152     <field name="handicap_adapt" type="string" indexed="true" stored="true" multiValued="true"/>
153
154     <!-- Numeric fields -->
155     <field name="lat" type="pdouble" indexed="true" stored="true"/>
```

Indexation du corpus

J'ai utilisé l'interface web Solr Admin pour indexer le corpus. Après avoir navigué vers la section Documents, j'ai sélectionné le type CSV, configuré le séparateur point-virgule, et spécifié les paramètres pour les champs multi-valués : f.thematiques.separator=|, f.type_ressource.separator=|, et f.handicap_adapt.separator=|. J'ai ensuite importé le fichier CSV traité.

Après l'indexation, la vérification dans la section Overview : Num Docs et Max Doc sont tous deux à 1149, Deleted Docs est à 0, et tous les champs définis dans le schéma sont correctement indexés.

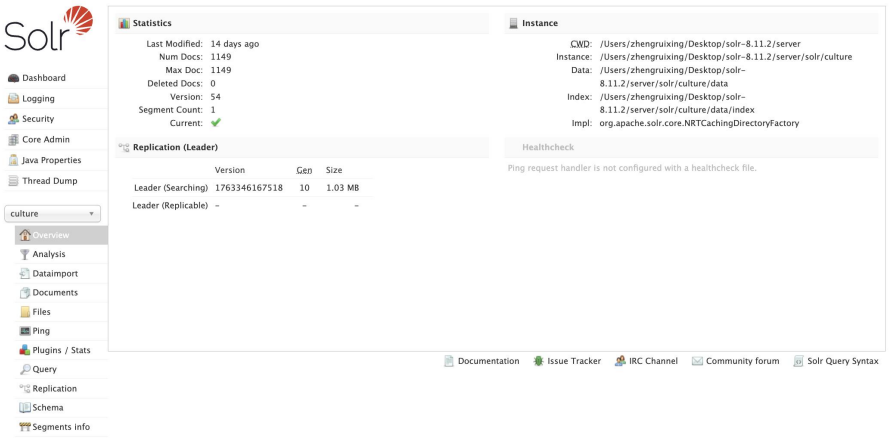

J'ai effectué plusieurs tests dans la section Query. La requête de base q=*:* retourne tous les 1149 documents avec les champs correctement peuplés et les facettes affichées avec les bonnes valeurs.

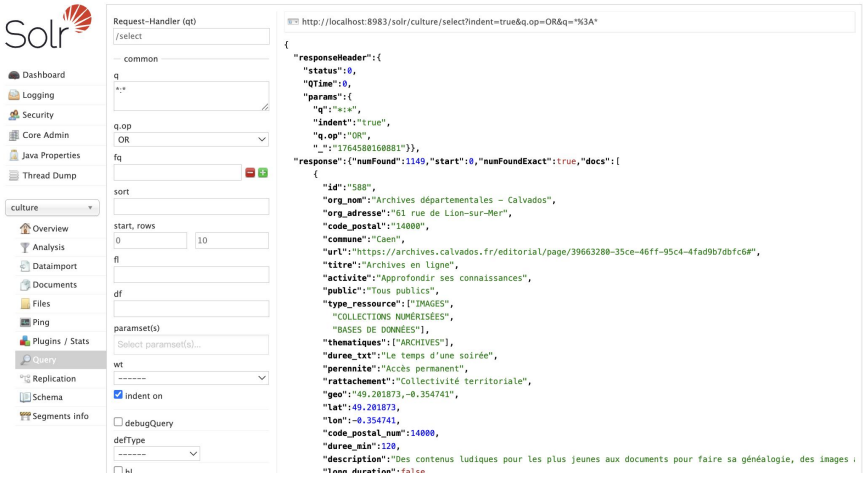

Création des facettes

J'ai configuré les facettes dans le requestHandler du fichier solrconfig.xml. Pour les Field Facets, j'ai activé quatre facettes de champ : thematiques, type_ressource, commune et public. Pour les Query Facets, j'ai créé trois facettes booléennes : is_for_kids:true, is_accessible:true et long_duration:true. Pour les Range Facets, j'ai configuré deux facettes d'intervalles : la durée en minutes avec un début à 0, une fin à 150 et un écart de 30, et la date de publication du 1er janvier 2022 au 27 août 2025 avec un écart d'un an. Enfin, pour les Pivot Facets, j'ai créé un croisement entre commune et type_ressource avec un compte minimum de 1.

solrconfig.xml

sktop/solr-8.11.2/server/solr/culture/conf/solrconfig.xml (functions)

```
<requestHandler name="/browse" class="solr.SearchHandler">
  <lst name="defaults">

    <!-- Velocity -->
    <str name="wt">velocity</str>
    <str name="v.template">browse</str>
    <str name="v.layout">layout</str>
    <str name="title">Culture Browser</str>

    <!-- Query -->
    <str name="defType">edismax</str>
    <str name="qf">
      titre^5.0
      description^3.0
      activite^2.0
      thematiques^3.0
      type_ressource^3.0
      commune^2.0
    </str>
    <str name="q.alt">*:*</str>
    <str name="rows">20</str>
    <str name="fl">*,score</str>

    <!-- ====================== -->
    <!-- FACET CONFIG SECTION   -->
    <!-- ====================== -->

    <str name="facet">on</str>
    <str name="facet.mincount">1</str>

    <!-- Field facets -->
    <str name="facet.field">thematiques</str>
    <str name="facet.field">type_ressource</str>
    <str name="facet.field">commune</str>
    <str name="facet.field">public</str>
```

Les résultats obtenus dans l'interface montrent pour les Field Facets : Thematiques avec MUSÉES (333), HISTOIRE (212), ARCHITECTURE ET PATRIMOINE (194) et ARTS VISUELS (192), Type_ressource avec EXPOSITIONS VIRTUELLES, VIDÉO, AUDIO, PODCASTS et IMAGES, Commune avec Paris en tête suivi de Lyon et Marseille, et Public avec Tous publics (948), Enfants (113) et Parents/Éducateurs (77).

Les Query Facets affichent 110 ressources pour les enfants, 180 ressources accessibles aux personnes handicapées, et 198 ressources de longue durée.

Les Range Facets indiquent pour la durée : 345 ressources de 0-30 min, 340 de 60-90 min et 265 de 120-150 min, et pour l'année : 327 en 2022, 332 en 2023, 300 en 2024 et 190 en 2025. Les Pivot Facets permettent d'explorer le croisement commune × type_ressource, par exemple Paris avec 15 VIDÉO et 13 EXPOSITIONS VIRTUELLES.

Il est important de noter que les comptages des facettes multi-valuées comme thematiques et type_ressource dépassent le nombre total de documents car un même document peut appartenir à plusieurs catégories. Par exemple, une exposition virtuelle peut être classée à la fois dans MUSÉES, HISTOIRE et PEINTURE. Cette caractéristique est normale et

permet une navigation plus riche.

Modification de Velocity

J'ai modifié plusieurs templates Velocity pour améliorer l'expérience utilisateur. Dans le fichier VM_global_library.vm, j'ai modifié la macro display_facet_range pour afficher les dates de manière plus lisible (afficher simplement "2023" au lieu de "2023-01-01T00:00:00Z - 2023-01-01T00:00:00Z+1YEAR") et renommé les labels pour plus de clarté ("Année" au lieu de "date", "Durée" au lieu de "duree_min").

VM_global_library.vm

sktop/solr-8.11.2/server/solr/culture/conf/velocity/VM_global_library.vm (no function selected)

```
#macro(display_facet_range $field, $display, $fieldName, $start, $end, $gap, $before, $after)
<span class="facet-field">
  ## 自定义字段显示名称
  #if($fieldName == "duree_min")
    Durée
  #elseif($fieldName == "date")
    Année
  #else
    $display
  #end
</span>
<ul>
  #if($before && $before != "")
    #set($value = "[* TO " + "#format_value($start)" + "}")
    #set($facetURL = "#url_for_facet_range_filter($fieldName, $value)")
    <li><a href="$facetURL">Less than #format_value($start)</a> ($before)</li>
  #end

  #foreach ($facet in $field)
    #set($rangeEnd = "#range_get_to_value($facet.key, $gap)")
    #set($value    = "[" + $facet.key + " TO " + $rangeEnd + "}")
    #set($facetURL = "#url_for_facet_range_filter($fieldName, $value)")
    #if ($facetURL != '')
      <li>
        <a href="$facetURL">
          ## 针对 date 字段，只显示年份
          #if($fieldName == "date")
            $facet.key.substring(0, 4)
          ## 针对 duree_min 字段，保持原样
          #elseif($fieldName == "duree_min")
            $facet.key - #format_value($rangeEnd)
          ## 其他字段保持原样
          #else
            $facet.key - #format_value($rangeEnd)
          #end
        </a>
        <span class="count">($facet.value)</span>
      </li>
    #end
  #end
```

J'ai effectué plusieurs tests pour valider le fonctionnement. Une recherche par mot-clé "paris" retourne 59 ressources avec les termes correctement surlignés et les facettes recalculées. Un filtrage par facette "MUSÉES" retourne 514 ressources avec ajustement automatique des autres facettes. Une combinaison "paris + MUSÉES" retourne 539 ressources avec navigation fluide. Et chaque résultat inclut un lien "Lire la suite" vers le site officiel, dont certains sont toujours actifs tandis que d'autres ont expiré (normal pour des données de 2022-2025).

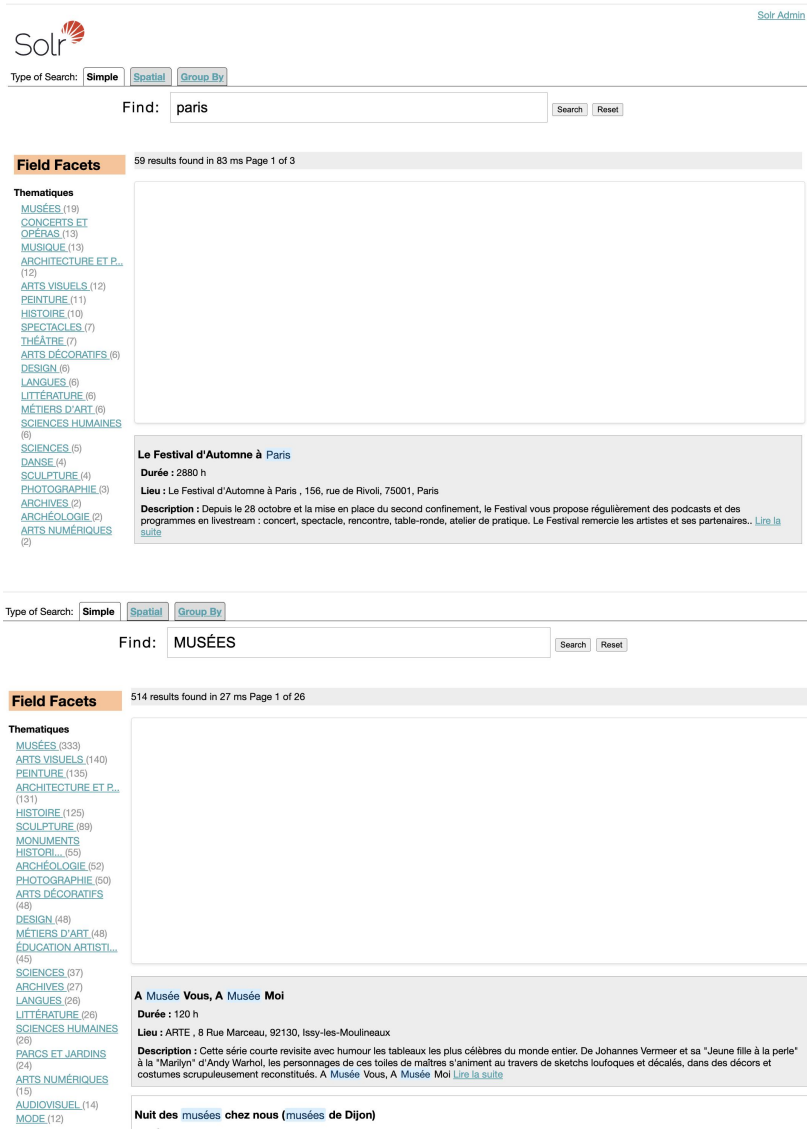

Difficultés rencontrées et perspectives

L'une des difficultés majeures est le mapping. Mon objectif était de créer une carte interactive affichant la localisation géographique des ressources culturelles. J'ai ajouté les bibliothèques Leaflet dans head.vm, créé un conteneur carte dans browse.vm pour faire une carte centrée sur la France. J'ai testé aussi le passage au fournisseur CartoDB, mais ça marche pas. Pour l'avenir, je prévois d'améliorer cette partie et d'ajouter un bouton "Afficher la carte" pour charger à la demande.

Conclusion

Ce projet m'a permis de construire un moteur de recherche et pertinent pour explorer des activités culturelles françaises. Et selon moi, les expériences acquises avec Solr constitue une base solide pour créer de plus en plus de projets de recherche d'information.

Note : L'ensemble du code source est fourni dans le dossier de soumission pour vérification et reproduction des résultats.